Automatización de la detección y clasificación de trazas de partículas en una cámara de niebla mediante redes neuronales convolucionales

Maria Alejandra Andrade Eraso, mariaa.andrade@udea.edu.co
Julian Ramirez Duque, julian.ramirezd@udea.edu.co
Sebastian Eladio Mena Torres, sebastian.mena@udea.edu.co
Mario Cesar Barrera Salas, mario.barrera@udea.edu.co

Enero 2026

Instituto de Física, Universidad de Antioquia, Medellin-Antioquia, Colombia

Resumen

En este informe se presenta un estudio experimental sobre el diseño, la construcción y el análisis de una cámara de niebla. El objetivo principal fue capturar mediante una webcam, trazas de radiación ambiental para entrenar un modelo de red neuronal capaz de detectar y clasificar partículas según su tamaño y grosor. Se identificaron trazas delgadas y erráticas asociadas a partículas beta, así como trazas densas y cortas correspondientes a partículas alfa. Los resultados muestran la posibilidad de integrar herramientas de inteligencia artificial en el monitoreo de eventos de partículas, sentando las bases para futuras fases experimentales con fuentes radiactivas que permitan obtener un mayor número de trazas y desarrollar un modelo más preciso y robusto.

Palabras clave: Cámara de niebla, trazas de partículas, partículas alfa, partículas beta, redes neuronales.

Abstract

This article presents an experimental study on the design, construction, and analysis of a cloud chamber. The main objective was to capture traces of environmental radiation using a webcam to train a neural network model capable of detecting and classifying particles according to their size and thickness. Thin, erratic traces associated with beta particles were identified, as well as dense, short traces corresponding to alpha particles. The results show the possibility of integrating artificial intelligence tools into the monitoring of particle events, laying the groundwork for future experimental phases with radioactive sources that will allow for a greater number of traces to be obtained and a more accurate and robust model to be developed.

Keywords: Cloud chamber, particle tracks, alpha particles, beta particles, neural networks.

1. Introducción

La visualización de partículas ha sido fundamental para el desarrollo de la física nuclear. Desde la invención de la cámara de niebla por C. T. R. Wilson, este dispositivo ha permitido observar directamente la trayectoria de partículas cargadas mediante la condensación de vapor en un medio supersaturado. Sin embargo, uno de los principales desafíos actuales no radica únicamente en la detección física de las trazas, sino en el procesamiento eficiente de la gran cantidad de información visual generada, lo que vuelve ineficiente su análisis manual.

En este contexto, el presente proyecto surge de la necesidad de automatizar la identificación y clasificación de eventos mediante el uso de técnicas de

inteligencia artificial. A través de la implementación de modelos de redes neuronales convolucionales (CNN), es posible clasificar trazas de partículas según su forma. Este informe documenta el diseño y la construcción de una cámara de niebla de bajo costo, así como el desarrollo de un sistema de visión artificial orientado a la clasificación de partículas en un entorno de radiación ambiental.

2. Marco Teórico

2.1. Principio de Funcionamiento de la Cámara de Niebla

La cámara de niebla opera bajo el principio de la ionización en medios sobresaturados. Según Wilson (1927), cuando una partícula cargada atraviesa un vapor en estado metaestable, interactúa electromagnéticamente con las moléculas del medio, arrancando electrones y creando una cadena de iones. Estos iones actúan como centros de nucleación alrededor de los cuales el alcohol se condensa instantáneamente, formando gotas macroscópicas que revelan la trayectoria de la partícula.

2.2. Características de las Partículas Detectadas

Para el entrenamiento de la red neuronal, es importante definir las características que el algoritmo debe aprender:
- Partículas Alfa (α): Son núcleos de Helio. Al ser masivas y tener doble carga positiva, tienen un alto poder de ionización. Como señala Knoll(2010), esto se traduce en trazas gruesas, cortas y rectilineas, ya que su gran masa impide que se desvíen fácilmente al colisionar con moléculas de gas.
- Partículas Beta (β): Son electrones o positrones de alta energía. Tienen una masa mucho menor y una sola unidad de carga. Su poder de ionización es bajo, por lo que dejan trazas finas, tenues y quebradizas, ya que colisionan y cambian de dirección con facilidad (dispersión).

2.3. Redes Neuronales Convolucionales (CNN)

En el contexto de la clasificación de imágenes, una CNN es una arquitectura de aprendizaje profundo diseñada para procesar datos con estructura de píxeles. El proceso se basa en dos etapas, la primera consiste en extracción de las características mediante capas de convolución, el modelo aplica filtros que detectan bordes, curvas y texturas. En nuestro caso, la red aprende a identificar el constraste de la traza frente al fondo oscuro; posteriormente las capas finales (densas) procesan las características extraídas para asignar una posibilidad a la imagen.

Esta arquitectura es particularmente eficiente para este proyecto porque utiliza convoluciones separables en profundidad (depthwise separable convolutions). Esto reduce significativamente la carga computacional sin sacrificar la precisión, permitiendo que el modelo pueda, en un futuro, clasificar partículas en tiempo real sobre un dispositivo móvil o una computadora portátil conectada a la cámara.

2.4. Gradiente Térmico y Difusión

La estabilidad de las trazas depende de la ley de difusión y del gradiente de temperatura (ΔT). El alcohol isopropílico es ideal debido a su bajo punto de congelación y su facilidad para alcanzar la saturación. El uso de un frasco más alto que ancho minimiza las corrientes de convección internas, las cuales podrían distorsionar las trazas y dificultar el análisis del modelo de IA.

3. Metodología

3.1. Construcción de la Cámara de Niebla:

Se utilizó un frasco de vidrio con un diámetro mayor a la altura para así maximizar el rango de visión y obtener una niebla mucho mas estable. En la base del frasco colocó una tela porosa de color negro y se aplicó pintura mate en los bordes internos. Esto es crítico para el entrenamiento de la red neuronal, ya que minimiza los reflejos parásitos que el algoritmo podría interpretar erróneamente como trazas.
Se vertió alcohol isopropílico al 90 % en la tela de la base. El sistema se colocó sobre un recipiente mas pequeño que contenía hielo seco (CO_2 sólido); al enfriarse la base, el vapor de alcohol en la parte superior se evapora y crea una zona de supersaturación. En esta región, cualquier partícula cargada que atraviese el gas actúa como un núcleo de condesación, revelando su trayectoria.



Figura 1: Frasco utilizado para hacer la cámara de niebla



Figura 2: Vista superior del frasco y su interior



Figura 3: Soporte con hielo seco

3.2. Captura de Datos y Procesamiento:

Se utilizó una cámara de alta resolución con iluminación lateral de la linterna de un celular y se grabó por largos periodos las trazas visibles. Los videos fueron descompuestos en cuadros individuales (frames). Se realizó una limpieza de datos eliminando aquellos frames donde el empañamiento del vidrio o reflejos externos obstruían la claridad de la zona de detección. Se procedió al etiquetado manual de las imágenes para el aprendizaje supervisado. Se definieron dos clases principales basadas en la firma física de la partícula:
- Partículas Alfa: Trazas con alta densidad de píxeles y trayectorias cortas.
- Partículas Beta: Trazas de baja densidad, filamentosas y frecuentemente curvadas.

3.3. Diseño y Entrenamiento de la Red Neuronal

Para el entrenamiento de la red neuronal, fue necesario construir un conjunto de datos (dataset) representativo a partir de las observaciones experimentales en la cámara de niebla. Se implementó un primer algoritmo, denominado 'Dataset', diseñado específicamente para procesar el flujo de video crudo y extraer regiones de interés (ROIs).

Este código opera iterando sobre los fotogramas del video experimental, aplicando filtros de preprocesamiento para reducir el ruido de fondo y resaltar las trazas de condensación. Posteriormente, el algoritmo recorta y guarda automáticamente las imágenes individuales de las trazas detectadas. Estas imágenes fueron etiquetadas manualmente para constituir la "verdad fundamental" (ground truth) del entrenamiento , todo esto mediante las libreria de OpenCV.

Para la clasificación automatizada, se utilizó la arquitectura MobileNetV2 como base, aprovechando su eficiencia computacional y capacidad de extracción de características mediante transfer learning. Se modificaron las capas densas finales para adaptarlas al número de clases de este experimento específico.

Luego con un segundo video pasado por el código de extraccion de imagenes, y generando un nuevo dataset, el cual fue introducido para que el modelo se encargará de clasificar las imágenes

4. Resultados

4.1. Generación del Dataset y Extracción de Características

El dataset final consta de un total de 250 imágenes, divididas en 3 categorías principales según la morfología y el origen físico de la partícula (alpha, beta , ruido). A continuación, se presentan muestras representativas utilizadas para entrenar el modelo:



(a) Alpha (b) Beta (c) Ruido

Figura 4: Algunos ejemplos de imágenes clasificadas para el entrenamiento.

4.2. 2. Entrenamiento del Modelo y Clasificación de Partículas

El proceso de entrenamiento arrojó resultados satisfactorios, alcanzando una precisión (accuracy) final del $97,96\,\%$ en el conjunto de validación y una

pérdida (loss) de 0.2113. Las curvas de aprendizaje demostraron una convergencia estable sin signos significativos de sobreajuste (overfitting).

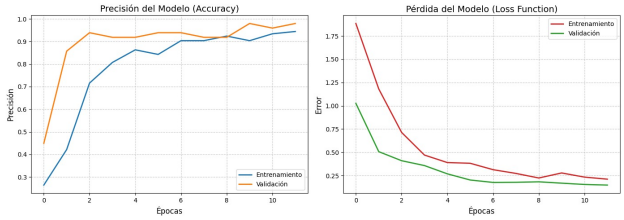


Figura 5: Gráficas de las métricas de aprendizaje del modelo.

Una vez validado el modelo, se procedió a la fase de inferencia utilizando un segundo script de análisis sobre un video experimental inédito (no visto por la red durante el entrenamiento). El sistema fue capaz de detectar y clasificar las trazas en tiempo casi real.



(a) Alpha (b) Beta (c) Ruido

Figura 6: Algunos ejemplos de las clasificaciones hechas por el modelo.

5. Conclusiones

Futuras mejoras experimentales podrían incluir un control más preciso del enfriamiento en la base de la cámara, así como un sistema de iluminación uniforme y constante que reduzca variaciones de contraste entre sesiones de captura. La incorporación controlada de fuentes radiactivas permitiría ampliar significativamente el dataset, mejorar el balance entre clases y reducir la incertidumbre asociada al etiquetado. Este trabajo sienta una base sólida para la integración de técnicas de inteligencia artificial en experimentos clásicos de física experimental. La combinación de mejoras en el diseño experimental con estrategias avanzadas de entrenamiento y validación del modelo permitirá sistemas de detección más precisos, escalables y potencialmente aplicables al monitoreo automatizado de radiación en tiempo real.

6. Referencias

[1] Wilson, C. T. R. (1911). On a method of making visible the paths of ionising particles through a gas. Proceedings of the Royal Society of London. Series A, Containing Papers of a Mathematical and Physical Character, 85(578), 285–291.
https://doi.org/10.1098/rspa.1911.0041https://www.nobelprize.org/prizes/physics/1927/wilson/lecture/

[2] Knoll, G. F. (2010). Radiation Detection and Measurement (4th ed.). Wiley.

[3] Leo, W. R. (1994). Techniques for Nuclear and Particle Physics Experiments: A How-to Approach. Springer-Verlag.

[4] Bradski, G. (2000). The OpenCV Library. Dr. Dobb's Journal of Software Tools. https://opencv.org

7. Anexos

Se adjunta el script desarrollado para la captura de frames, el preprocesamiento con la librería OpenCV y la inferencia del modelo utilizando TensorFlow y MobileNetV2.

Codigo Dataset:
https://colab.research.google.com/drive/1qa1fLwwR6VjgfnPDe2YOgP8GTxWamPCm?usp=sharing

Codigo Entrenamiento y analisis :
https://colab.research.google.com/drive/1iWi0FZvBR29ap5SGqIbQWUC11AJBXZvo?usp=sharing